

MPTCP

Performances et optimisation de la sécurité avec un ordonnancement réparti dans les topologies virtualisées OpenFlow

Encadrants : S. Secci,
Y. Bouchaib, M. Coudron,

Etudiants : R. Ly, K. Lam, Q. Dubois, S. Ravier

Table des matières

1	Cahier des charges	3
1.1	Objectifs	3
1.2	Contexte	3
1.3	Méthodes	3
2	Plan de développement	5
2.1	Descriptif du travail de Quentin Dubois et de Kevin Lam	5
2.2	Descriptif du travail de Romain Ly	6
2.3	Descriptif du travail de Simon Ravier	7
3	Contexte technologique	8
3.1	Fonctionnement de MPTCP	8
3.2	Utilisation réelle de MPTCP	10
3.3	MPTCP et sécurité	10
4	Analyse	12
4.1	Topologies virtualisées	12
4.1.1	Multi-chemins simple	12
4.1.2	FatTree	12
4.1.3	MPTCP vs TCP	12

4.2	Performances de MPTCP	13
4.3	Conception algorithme sécurisé	13
4.4	Test de l'algorithme d'ordonnancement	14
5	Conception	15
6	Compte rendu du projet	16
6.1	Outil de coordination : git	16
6.2	Compilation MPTC	16
6.3	Topologie	16
6.4	Performance de MPTCP sur mininet	16
6.4.1	Un exemple de démonstration	17
6.4.2	Variation du débit maximal par lien	18
6.4.3	Variation du délai par lien	21
6.4.4	Choix du sous-flot en fonction du délai	22
6.5	Etude de l'algorithme de MPTCP	27
6.5.1	Explication de l'ordonnanceur	27
6.6	Choix de l'ordonnanceur	28
6.7	Implémentation de l'ordonnanceur	29
7	Annexe1	31
7.1	Utilisation des scripts pythons	31
7.1.1	Activation MPTCP	31
7.1.2	Choix de l'algorithme congestion	31
7.1.3	Taille de la fenêtre	32
7.2	Lancement scripts python	32
7.3	Résumé des arguments pour le parseur	33
7.4	arguments mininet	33
7.4.1	ssh	34
7.5	scripts shell	34
7.6	Scripts R	35
7.7	Bugs	35
7.7.1	Topologie	35
7.7.2	mininet	35
7.8	Expériences	36

1 Cahier des charges

1.1 Objectifs

Les objectifs du projet sont de :

- mesurer les performances de MPTCP sur différentes topologies de réseaux virtuels.
- modifier l'ordonnanceur de MPTCP pour privilégier une répartition équilibrée sur les différents sous-flots.

1.2 Contexte

MPTCP est une extension de TCP qui permet pour une connexion TCP donnée d'utiliser plusieurs chemins pour l'échange de données. La multiplicité des sous-flots a pour but d'améliorer le débit et d'augmenter la résilience de la connexion [1–3].

Les performances de MPTCP ne doivent pas être inférieures à celles de TCP et son utilisation ne doit pas diminuer le débit des autres utilisateurs sur le même réseau. Les performances de MPTCP dépendent en partie de l'algorithme utilisé pour la répartition des données entre les différents sous-flots ouverts [4]. Pour caractériser les performances de l'ordonnanceur de MPTCP, nous allons le tester dans différents réseaux virtualisés en utilisant dans un premier temps l'algorithme implémenté dans le kernel MPTCP de linux¹.

L'emploi de MPTCP améliorerait la sécurité si les données transitaient de manière équilibrée entre les différents sous-flots, ce qui complexifierait les attaques. Le débit global de la connexion serait affecté car les chemins les plus lents vont ralentir le débit des chemins les plus rapides, ce qui, en contre partie, peut s'avérer moins performant qu'une simple connexion TCP. Nous allons modifier l'ordonnanceur afin de garantir la répartition équitable des charges puis analyser l'influence de cette modification sur les performances de MPTCP dans les topologies réseaux utilisées précédemment.

1.3 Méthodes

La réalisation du projet peut être subdivisée en trois parties :

- la simulation de réseaux à topologies différentes,
- l'analyse des performances de MPTCP,
- l'adaptation de l'ordonnanceur pour l'aspect sécurité.

Nous utiliserons Mininet afin de simuler les topologies réseaux où nous pourrions mesurer les performances de MPTCP à l'aide de l'API Python fournie par Mininet. Pour caractériser l'influence de l'ordonnanceur sur les performances, nous utiliserons des réseaux simples où les différents sous-flots sont asymétriques et diffèrent par une propriété à la fois : latence, débit, pertes... Nous testerons différents algorithmes de répartition de charge entre sous-flots : l'algorithme implémenté par défaut (LIA), celui qui satisfait l'optimum

1. mptcp.org

de pareto par rapport aux objectifs de MPTCP, ou encore un algorithme de répartition équilibrée de la charge réseau entre les différents sous-flots.

2 Plan de développement

La première partie est de consulter les topologies virtualisées et de tester les performances de MPTCP en faisant varier les paramètres des sous-flots. La seconde partie est de construire un algorithme d'ordonnancement répondant à des critères de sécurité.

Les étapes du développement suivront les points suivants :

- Préparation d'une machine mininet avec le noyau MPTCP compilé pour l'ensemble de l'équipe ;
- Lecture, compréhension et commentaires du code de MPTCP ;
- Préparation de plusieurs topologies : *fat tree* pour simuler un *data center* et une topologie permettant de tester la concurrence entre MPTCP et TCP ;
- Préparation d'une bibliothèque de tests et de mesures via l'API python ;
- Écriture d'un algorithme d'ordonnancement dans le noyau ;
- Mesures de performance.

2.1 Descriptif du travail de Quentin Dubois et de Kevin Lam




FIGURE 1 – Diagramme de Gantt Kevin Lam et Quentin Dubois.

Analyse de la structure de l'implémentation :

Déterminer globalement les fichiers à lire ;

Définir les headers et structures liés à l'utilisation de mptcp.

Lecture et Compréhension du code :

Lecture de tous les fichiers contenus dans $\$(SRC_NOYAU)/net/mptcp$;

Lecture de certains fichiers contenus dans $\$(SRC_NOYAU)/net/sched$;

Lecture de tous les types/structures utilisés ;

Relecture du code après avoir compris tous les types/structures.

Définition des parties modifiables de l'ordonnanceur :

Vérifier les correspondances entre `mptcp_output.c` et `mptcp_input.c` ;

Voir si l'utilisation du contrôle de congestion (`mptcp_olia.c` et `mptcp_coupled.c`) a des effets de bord sur les sockets ;

Voir les différences entre les différents modes du `path_manager`.

Implémenter / Tests d'algorithmes pour l'ordonnanceur

Avec l'aide de Matthieu Coudron, modification dans $\$(SRC_NOYAU)/net/mptcp/mptcp_output.c$;

Tests des implémentations avec le travail de Romain LY et comparer les résultats obtenus.

2.2 Descriptif du travail de Romain Ly




FIGURE 2 – Diagramme de Gantt de Romain Ly.

- Mise en place du Git
- Compilation noyau MPTCP dans la VM mininet et tests simples de routines
- Topologie modifiée de Khalili et al.
- Scripts Python
 - implémentation d'un parseur d'arguments
 - intégration de ping, iperf, iperf3, bwm-ng, sshd, tcpdump permettant le monitoring et l'étude du réseau
- Installation de TCP-reduce dans la VM pour vérifier les options de la connexion TCP.
- Scripts Bash pour générer de multiples simulations par l'intermédiaire de scripts Python
- Scripts R pour analyse des résultats et figures
- Débogages des scripts
- Expérimentations
 - variation du nombre de sous flots, débits, latences, taille de fenêtre, etc.




FIGURE 3 – Diagramme de Gantt de Simon Ravier.

2.3 Descriptif du travail de Simon Ravier

- 03/03 au 30/03 établissement de la topologie FatTree
- 31/03 au 06/04 modification de la topologie FatTree (impossibilité technique de réaliser le premier modèle)
- 07/04 au 27/04 Intégration de la topologie FatTree dans l'environnement de tests (configuration des hôtes, établissement des tables de routage) et réalisation des tests

3 Contexte technologique

L'élaboration de MPTCP a été motivée par l'observation de l'existence dans les réseaux de plusieurs chemins entre deux machines A et B. L'utilisation de ces différents chemins entre les deux hôtes pourrait être un atout non négligeable pour augmenter le débit de la connexion et/ou la résilience de la connexion si l'un des chemins venaient à ne plus pouvoir acheminer les paquets (congestion, panne de routeur, etc). De plus le multi-chemin permet d'équilibrer la répartition des charges sur les sous-flots utilisés. TCP n'a pas été conçu pour exploiter plusieurs chemins d'où la nécessité de concevoir des protocoles multi-chemins comme MPTCP permettant d'utiliser les chemins disponibles pour transmettre les paquets d'une connexion entre A et B via les sous-flots connectés.

Il existe déjà plusieurs protocoles proposant d'utiliser plusieurs chemins. Nous en citerons que deux : SCTP et ECMP. SCTP (*Stream Control Transmission Protocol*) allie l'avantage de TCP et UDP et permet de multiplexer les flux sur plusieurs interfaces [5]. ECMP (*Equal Cost MultiPath*) est un protocole qui semblait prometteur dans les data center. Lors d'une connexion entre deux hôtes, le routeur peut transférer les paquets sur plusieurs meilleurs chemins à coûts « égaux » [6]. L'inconvénient de SCTP est la nécessité que tous les hôtes terminaux puissent comprendre le protocole ; il est donc nécessaire de modifier la couche application pour pouvoir l'utiliser. ECMP nécessite le travail des routeurs pour connaître les chemins et l'augmentation de performance n'est pas forcément significative. L'avantage de MPTCP est d'être transparent par rapport à TCP, c'est à dire que si un hôte n'est pas compatible avec MPTCP, la connexion retournera vers une connexion TCP classique. L'autre avantage est qu'il est totalement transparent pour les routeurs, c'est une connexion *end to end*.


3.1 Fonctionnement de MPTCP

MPTCP utilise dans un premier temps une connexion TCP pour créer des sous-flots similaires à TCP avec des chemins différents. La couche TCP est alors remplacée par la couche MPTCP qui est divisée en deux parties (Fig. 4) : la couche supérieure correspond aux fonctions nécessaires à MPTCP de fonctionner (découverte et gestion des chemins, ordonnancement des paquets, contrôle de congestion) et la couche inférieure correspond aux sous-flots établis.

MPTCP permet l'augmentation du débit de manière à ce qu'il soit supérieur à une connexion TCP unique sur le meilleur des chemins disponibles. Il permet aussi la résilience de la connexion en cas de panne ou de congestion, dans ce cas le trafic est alors réparti et/ou réexpédié sur les autres sous-flots sans la nécessité de rétablir une connexion TCP entre les deux terminaux. Cette approche permet de répartir les charges sur les ressources disponibles.

MPTCP implémente plusieurs fonctions pour contrôler les sous-flots de la connexion [1]

- le gestionnaire de chemin ou *path manager*
- l'ordonnanceur de paquets (*packet scheduling*)
- le contrôleur de congestion

FIGURE 4 – Schéma de la pile MPTCP. source : www.cisco.org

Le sous-flot prend en charge les segments de l'ordonnanceur pour l'envoyer sur un chemin disponible. Le sous-flot agit comme une connexion TCP classique et dispose de cette manière des fonctions de ce protocole de transport assurant d'envoyer des paquets de manière fiable et séquencée. À la réception, le sous-flot envoie les segments à la couche ordonnanceur de paquet pour le réassemblage.

Le gestionnaire des chemins est le mécanisme permettant de détecter et d'utiliser les chemins disponibles par l'intermédiaire de multiples adresses IPs dans les hôtes. Il signale l'existence d'adresses alternatives et permet d'intégrer de nouveaux sous-flots à une connexion MPTCP existante ou d'en enlever.

L'ordonnanceur des paquets découpe le flux de données provenant de la couche application en segments prêts à être envoyés par l'un des sous-flots. Il séquence les segments et permet de réassocier les segments pour réordonner les données côté destinataire. L'ordonnanceur dépend des informations des chemins disponibles provenant du gestionnaire de chemins [7].

Enfin, le contrôle de congestion est un outil essentiel qui permet d'adapter le débit de chaque sous-flot et de définir si un chemin est trop lent par rapport au meilleur sous-flot. Il permet aussi de renvoyer l'information au gestionnaire s'il y a une panne.

Le contrôle de congestion nécessite un algorithme performant pour que l'utilisation de MPTCP à la place de TCP puisse effectivement augmenter le débit de l'utilisateur sans influencer le débit des autres utilisateurs sur les mêmes chemins, c'est à dire qu'il doit garantir l'optimalité de pareto. L'algorithme de MPTCP est donc un point central dans les performances de MPTCP sur le réseau.

Lors des choix des sous-flots, l'algorithme doit effectuer un compromis entre équilibre des charges dans les différents sous-flots et réactivité (*responsiveness*) en cas de modification de la latence des sous-flots ou de découverte de nouveaux chemins. Une priorité

vers l'équilibre des charges entraîne l'envoi des données sur les meilleurs routes (selon la métrique utilisée, par défaut la latence du chemin) mais cela peut déclencher un changement constant de route produisant un effet de battement (*flappiness*) : si plusieurs chemins possèdent le même coût, l'algorithme aura tendance à changer plus souvent de chemins. Si la priorité utilisée est la réactivité (par augmentation de la taille de la fenêtre d'un des sous-flot), l'utilisation de toutes les ressources disponibles peut ne pas être optimale car on aura tendance à utiliser qu'un seul sous-flot. Les paramètres de l'algorithme doivent être déterminés efficacement pour répartir les charges sur les sous-flots et ne pas être agressif (augmentation trop rapide de la taille de la fenêtre sur un des sous-flots) pour garantir l'optimalité de Pareto [4].

Dans l'algorithme par défaut, le critère privilégié par l'algorithme est le RTT. Il serait intéressant de modifier les caractéristiques du réseau pour mesurer les performances de MPTCP sur le choix des chemins utilisés ou en cas de modification de chemins sur des critères de latence, pertes, débit ...

3.2 Utilisation réelle de MPTCP

Dans la pratique, l'utilisation de MPTCP est difficile. L'utilisation de plusieurs sous-flots ne garantit pas l'augmentation de débit. Pour cela, il est nécessaire que les sous-flots empruntent des chemins physiques différents et aujourd'hui il n'est pas possible pour un utilisateur de contrôler le routage de ses paquets de bout en bout. Une méthode pour contourner le problème serait d'utiliser la conjonction de MPTCP et de LISP (*Locator/Identifier Separation Protocol*) qui permet de découvrir la diversité de chemins existant entre routeurs de bordures (A-MPTCP) [3].

Cependant il existe des cas où MPTCP est utilisable à son plein potentiel et suscite l'intérêt : dans les datacenters et en environnement mobile. Par l'intermédiaire d'une stratégie de routage par SDN (*Software Defined Network*) par exemple OpenFlow, le contrôleur peut établir des chemins différents entre deux hôtes sur tout son réseau. Le transfert de données au sein d'un datacenter nécessite des débits très importants. L'utilisation de MPTCP pourrait répartir les charges entre les différents noeuds. Des expériences sur différentes topologies de datacenter à haute densité ont permis de montrer que MPTCP égale, voir surpasse même la performance d'un ordonnanceur centralisé et est de surcroît plus robuste [8]. En mobile, le terminal pourra utiliser le réseau 3G/4G et le réseau wi-fi environnant. MPTCP permettra de décharger le réseau téléphonique de l'opérateur tout en augmentant le débit et la résilience de la connexion.

3.3 MPTCP et sécurité

À l'heure d'Eric Snowden, l'utilisation de plusieurs sous-flots pourrait être un avantage non négligeable en terme de sécurité. Pour pouvoir épier une connexion entre A et B, il faudrait à l'attaquant de pouvoir *sniffer* les paquets qui sont émis sur les sous-flots utilisés, c'est-à-dire sur autant de chemins physiques différents. L'intérêt du multi-chemin prend alors tout son sens. Cependant ce n'est pas le seul avantage, on peut réfléchir à plusieurs

moyens d'augmenter la sécurité par l'utilisation du multi-chemin conjointement avec une modification des protocoles de sécurité.

Par exemple, l'utilisation de chiffrement de type CBC (*Cipher Block Chaining*) compliquera l'attaquant car il sera nécessaire d'obtenir le bloc $n-1$ pour déchiffrer le bloc n . AES-CBC est utilisé couramment dans des communications de type HTTPS/SSL. L'attaquant devra disposer de tous les paquets sans exception pour pouvoir déchiffrer le message en supposant qu'il possède la clé adéquate.

De plus, si les protocoles de sécurité sont conscients de l'utilisation de MPTCP, il pourrait y avoir une entente *cross-layer*. Par exemple, en distribuant les informations des MAC (*Message Authentication Code*) de chaque paquet entre les différents sous-flots de manière à éviter les *man in the middle* : sous flot 1 = message 1 + HMAC (message 2) ; sous flot 2 = message 2 + HMAC (message 1). Un autre exemple serait de négocier les clés pour le chiffrement de la communication d'un sous-flot (par exemple en utilisant IPSec) dans le sous-flot adjacent.

Dans tous les cas, il est donc nécessaire que MPTCP dans une optique sécurité utilise au minimum deux sous-flots. Dans une première approche simpliste, il serait intéressant de forcer l'algorithme de MPTCP à répartir les paquets équitablement sur plusieurs sous-flots, quitte à diminuer les performances de MPTCP.

4 Analyse

4.1 Topologies virtualisées

Nous allons simuler des topologies openFlow en utilisant mininet. Les switches seront virtualisés par openvSwitch (OVS) qui est installé par défaut dans l'image mininet. Pour utiliser le multi chemin, le noyau de MPTCP sera compilé dans la machine virtuelle et chaque hôte sera configuré de manière adéquate pour pouvoir utiliser MPTCP.

Nous créerons et testerons les topologies virtuelles grâce à l'API python.

4.1.1 Multi-chemins simple

La topologie simple est composée de deux hôtes et de N switches. Les N switches composeront les N chemins disponibles. Cette topologie simple servira principalement au test de fonctionnement de MPTCP.

4.1.2 FatTree

Afin de tester MPTCP de manière réaliste, nous avons simulé une topologie Fat-Tree, souvent utilisée dans les datacenters qui sont les premiers nécessitent des performances offertes par MPTCP. Cette topologie repose sur le principe d'établir plusieurs liens physiques entre deux équipements réseau, en l'occurrence des switches. Tous les switches du réseau ont le même nombre de ports; ils sont organisés par couches : une couche « coeur », une couche « frontière » et une couche « hôtes ». Les couches hôtes et coeurs sont directement connectées à la couche frontière, mais pas entre elles. Chaque switch de la couche coeur est connecté à chaque switch de la couche frontière par de multiples liens. Le nombre de ports disponibles sur les switches coeurs est équitablement réparti entre chaque switch frontière; ainsi, avec deux switches coeurs et quatre switches frontières à 36 ports, on disposera de 9 liens entre chaque paire de switches de couches différentes. Le reste des ports disponibles sur les switches frontières sont utilisés pour y connecter les hôtes, à raison d'un lien par hôte. Notons que deux équipements d'une même couche ne sont jamais interconnectés.

4.1.3 MPTCP vs TCP

Pour déterminer les critères à respecter de l'ordonnanceur (celui par défaut, ou l'OLLIA) et conserver les principes de MPTCP (équité avec les utilisateurs TCP et performances supérieures à TCP), nous allons reproduire le *testbed* utilisé dans l'article de Khalili (Fig. 5).

Si nous pouvons reproduire les résultats obtenus par Khalili avec notre configuration, nous reproduirons le cas avec N1 utilisateurs MPTCP et N2 utilisateurs TCP (voir Fig. 6).

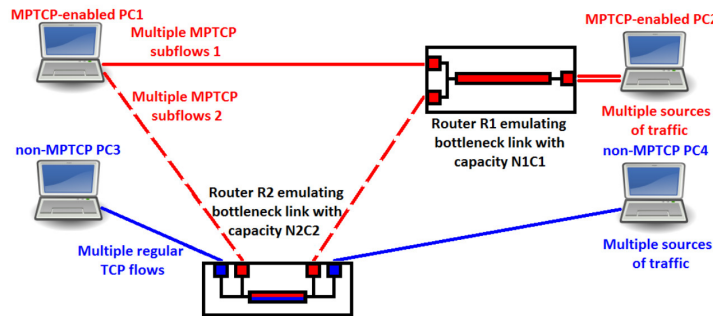



FIGURE 5 – Testbed MPTCP vs TCP [4].

FIGURE 6 – Testbed MPTCP vs TCP [4]. Les N_1 utilisateurs MPTCP (rouge) utilisent deux points d'accès pour se connecter à un serveur distant dont un qui est partagé avec les N_2 utilisateurs TCP (bleu).

4.2 Performances de MPTCP

Pour mesurer les performances de MPTCP, nous allons faire varier les propriétés de chaque sous-flot emprunté en modifiant les chemins de manière asymétrique. Le but est de créer des conditions de stress qu'on pourra tester à la volée avec les différents algorithmes gérant MPTCP (celui par défaut, l'OLIA et le notre si celui-ci est opérationnel) et sur les différentes topologies virtuelles construites.

Les contraintes appliquées auront comme critères la latence (critère actuellement privilégié par l'ordonnanceur pour les choix de sous-flots), la capacité, le taux d'erreurs, la gigue, etc. Nous testerons quelle est l'influence de ces paramètres sur le choix des sous-flots par l'ordonnanceur.

4.3 Conception algorithme sécurisé

Le but est de rendre une connexion plus sécurisée par la complexité de l'analyse des paquets de données échangés entre deux utilisateurs. Nous chercherons à faire une méthode simple et non performante pour effectuer des tests et savoir comment MPTCP réagit au

nouvel algorithme de répartition des paquets dans les sous-flots TCP. Cette méthode consiste à prendre le nombre de sous-flots total et de répartir les segments équitablement entre les différents sous-flots. Le débit de chaque sous-flot correspondra au débit le plus faible des sous-flots. Cela reste une solution de l'objectif noté dans le cahier des charges.

Néanmoins il sera nécessaire d'avoir un algorithme plus intelligent. En effet, il est nécessaire d'avoir un meilleur algorithme que celui expliqué ci-dessus car la performance pourrait être grandement affectée. Le débit pourrait être bien plus faible qu'une connexion TCP classique sur le meilleur des chemins si un des chemins a un débit beaucoup plus faible ou s'il est congestionné. Or même si nous voulons accroître la sécurité il est préférable d'avoir au moins le débit d'une connexion TCP simple. La difficulté dans cette partie est de pouvoir adapter l'ordonnanceur selon le nombre de sous-flots disponibles. Une idée serait de répartir les charges de manière à que l'ordonnanceur de paquets n'envoie plus de $50 + \varepsilon$ % des segments à un unique sous-flot. Ce nombre pourrait être variable selon d'autres paramètres comme le nombre de sous-flots disponibles.

4.4 Test de l'algorithme d'ordonnancement

L'écriture et le test de l'algorithme d'ordonnancement dans le noyau linux peut s'avérer une tâche difficile en si peu de temps. Pour tester la validité de notre algorithme d'ordonnancement, nous réfléchissons à effectuer d'abord un *proof of concept* en utilisant directement python qui utilisera des fonctions de *callback* pour certaines fonctions du noyau nécessaire à MPTCP. On utilisera alors UDP pour la transmission des données.

5 Conception

6 Compte rendu du projet

6.1 Outil de coordination : git

L'état des scripts utilisés par l'équipe est mise à jour par un système de version utilisant git <https://github.com/Romain-Ly/PRES>.

6.2 Compilation du noyau MPTCP (machine test)

Pour la réalisation du projet, nous utilisons une machine virtuelle ubuntu 13.04 (32 bits) où mininet est installé et est prêt pour utilisation : <https://bitbucket.org/mininet/mininet-vm-images/downloads>.

Nous avons compilé le noyau linux contenant MPTCP (v0.88) dans une VM de mininet (v2.10). Les paquets debian pour l'installation du noyau MPTCP sur une VM de mininet est disponible : (<https://www.dropbox.com/sh/y4ykck8rg6908ps/7V3lsV6Ggg>).

Cependant, l'architecture des machines pouvant être différente, la VM n'est pas fonctionnelle sur certaines des machines des membres du projet. Par conséquent, il est préférable de compiler soit même MPTCP dans chaque machine. Le fichier ".config" est disponible sur le git. La seconde option est d'utiliser "apt-repository" selon les indications disponibles à cette adresse <http://multipath-tcp.org/pmwiki.php/Users/AptRepository>.

6.3 Topologie

Nous utilisons principalement deux topologies (A et B).

La topologie A est inspiré du *testbed* de l'article de R. Khalili [4], voir Fig. 7. Nous avons ajouté, à cette topologie, des routeurs privés entre le client et le serveur *MPTCP* pour disposer d'un nombre de sous-flots supérieur à deux.

La topologie B correspond au *fat tree*.

6.4 Performance de MPTCP sur mininet

Après la compilation du noyau, pour vérifier le fonctionnement de MPTCP nous avons mesurer le débit moyen en utilisant *iperf* sur la topologie A.

Les paramètres¹ utilisés sont les suivants :

Paramètre	Valeur
MSS	1460 octets ²
window size	85,3 Koctets
délai par lien	10 ms
Algorithme de congestion	LIA [7]

1. paramètres par défaut dans le noyau Linux




FIGURE 7 – **Reproduction de la topologie de l'article de R. Khalili.** Le(s) *switch(s)* “S(n)” ne sont présent(s) que si le nombre de sous-flots est supérieure à deux. Pour n sous-flots, il y aura $n - 2$ *switchs* et $n - 2$ liens supplémentaires. L'hyperviseur est connecté à tous les *switchs*. Pour se connecter via ssh aux hôtes, un *switch* « root » est créé et est connecté au *switch* sw_mp1 (non représenté ici) voir utilisation CF `linktobeadded`.

6.4.1 Un exemple de démonstration

Nous allons prendre, dans cet exemple, une connexion avec deux sous-flots avec une capacité individuelle de 100 Mbit/s. Voici la commande pour générer cet exemple :

```
sudo python ./pyMPTCP -O exp001_TC --bw 100 -t 30 -n 2 --mptcp --bwm_ng
```

Pour les détails de l'activation de MPTCP dans le noyau et l'utilisation des arguments des scripts python, une notice est donnée en Annexe 1 : voir sections 7.1 page 31 et 7.3 page 33.

Le RTT entre $h1$ et sv_mp1 est de 44 ± 11 ms (mesuré avec la commande *ping*), ce qui correspond au RTT attendu pour traverser deux liens aller-retour. La moyenne ici tient compte du RTT du premier paquet qui est envoyé vers le contrôleur pour que celui-ci établisse le chemin vers le serveur.

L'argument “`--bwm_ng`” permet de lancer Bandwidth Monitor NG¹ (*bwm-ng*). Cette application mesure plusieurs paramètres : le nombre d'octets, de paquets, le débit entrant ou sortant passant par chacune des interfaces de l'hôte sondé. La figure 8 représente le débit entrant enregistré au serveur pour ses deux interfaces. Nous observons pour deux sous-flots aux capacités identiques et au coût identique, que le débit mesuré est quasi similaire (une différence de quelques paquets est observée).

Pour mesurer le débit total généré, nous effectuons une moyenne des débits totaux mesurés toutes les secondes par *iperf* entre 5 secondes après le début de la connexion, et 1 seconde avant la fin de la connexion. Nous observons pour cet exemple, côté serveur,

1. <http://www.gropp.org/?id=projects&sub=bwm-ng>




FIGURE 8 – Débit entrant côté serveur. échantillonnage : 2 Hz.

un débit maximal de 168 Mbit/s. Ce débit est cohérent par rapport aux mesures de débit *via* bwm-ng.

6.4.2 Variation du débit maximal par lien

Pour connaître les limites de nos simulations, nous avons fait varier la capacité de chaque sous-flot, ainsi que le nombre de sous-flots dans la topologie A.

Le débit totale mesuré au serveur croît linéairement avec l'augmentation du nombre de sous-flots pour des capacités par lien de 10 à environ 100 Mbit/s. Cette phase est en adéquation avec le but de MPTCP : augmentation des performances [1]. Cependant, pour les liens aux capacités supérieures à 100 Mbit/s, les performances décroissent rapidement et tombent en dessous des performances d'une simple connexion TCP ce qui viole la nature même de MPTCP.

Ce problème pourrait être expliqué par une utilisation non optimale de la capacité des sous-flots. Le *bandwidth delay product* (BDP) implique une taille minimale du tampon de réception. Pour un débit de 1000 Mo et un RTT de 44 ms, la taille minimale du tampon est de 5,5 Mo. Sachant que le tampon de réception¹ est partagé pour tous les sous-flots

1. dans notre simulation la taille des tampons de réception est la même que la taille des tampons




FIGURE 9 – **Débit total mesuré en fonction de la capacité du sous-flot.** Les débits sont mesurés avec *iperf* pour une connexion TCP classique et une connexion MPTCP contenant de 2 à 6 sous-flots.

d'une connexion MPTCP, la taille minimale du tampon doit suivre cette formule [2] :

$$buffer_size \geq \max(\{RTT_i\}_{i \in [1,n]}) * \sum_{i \in [1,n]} Bandwidth_{\{i\}} \quad (1)$$

C'est à dire que la taille du tampon de réception doit être supérieure ou égal au produit du RTT le plus élevé parmi tous les sous-flots et la somme des capacités de tous les sous-flots. Cette taille de tampon garantit l'utilisation optimale du lien lorsque des paquets nécessitent d'être retransmis sur des sous-flots aux délais lents. Dans notre simulation, il n'y a pas de perte de paquets, la valeur minimale des tampons correspond au BDP le plus élevé.

Pour les mêmes propriétés de liens, avec deux sous-flots, nous obtenons une taille minimale de 11Mo. Mininet modifie automatiquement les tampons au lancement de la topologie et les valeurs utilisées sont les suivantes (en octets) :

```
net.core.wmem_max = 16777216
```

d'envoi.

```

net.core.wmem_default = 163840
net.core.rmem_max = 16777216
net.core.rmem_default = 163840
net.ipv4.tcp_wmem = 10240 87380 16777216
net.ipv4.tcp_rmem = 10240 87380 16777216
net.ipv4.tcp_mem = 19326 25768 38652

```

Nous observons que le tampon maximal pouvant être alloué par socket est de 16 Mo environ ce qui est largement supérieur à la taille requise. De plus en augmentant la taille du tampon, nous n'observons pas d'augmentation de performances alors qu'en le diminuant, nous observons une diminution du débit mesuré (voir Fig. 10).

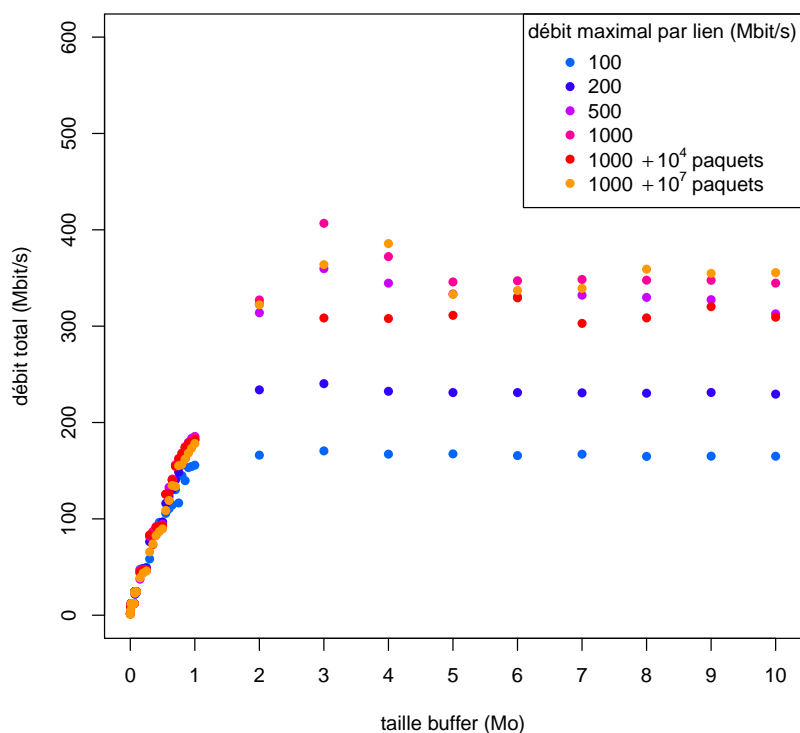


FIGURE 10 – **Débit mesuré en fonction de la taille de la fenêtre.** La taille maximale de la fenêtre TCP est modifiée avec l'argument '-w' avec *iperf*. La taille obtenue est étrangement deux fois supérieure à la taille demandé. Le nombre de paquets indiqué dans la légende correspond à la capacité de traitement, en nombre de paquets, des routeurs.

Nous obtenons les mêmes résultats en modifiant la capacité des routeurs ou en modifiant les valeurs de la taille des tampons dans le noyau (voir 7.1.3 page 32) que ce soit les paramètres minimum, par défaut et maximum d'*auto-tuning* de TCP (*net.ipv4*) ou les

valeurs maximales ou par défaut pour tous les type de connexions (*net.core*). Une vérification de la charge CPU global avec *htop* ne montre pas une saturation des processeurs (environ 15 % d'utilisation) cependant, il reste à implémenter *cpuacct* pour vérifier la charge CPU par conteneur.

En effectuant des recherches^{1 2}, il semblerait que la limite du débit est lié aux nœuds Open vSwitch sur Ubuntu 13.04, ce qui pour une dizaine de liens, limite la capacité maximale à environ 100 Mbit/s. C'est pourquoi, nous limiterons la capacité des liens à de faibles valeurs.

6.4.3 Variation du délai par lien

Afin d'évaluer l'influence du délai sur le débit enregistré, le délai de tous les liens varie de manière symétrique. Le coût pour chaque sous-flot reste donc identique.

Pour mesurer le délai de chaque sous-flot, nous avons utilisé la commande *ping*. Cette approche a été utilisée car elle est la plus facile à mettre en œuvre. Par manque d'espace disque (mémoire SSD), l'utilisation de *tcpdump* est réservée pour les tests et la recherche d'erreur. Cependant, il sera nécessaire d'utiliser le délai avec TCP car cette méthode est plus fiable et l'utilisation conjointe de *ping* et d'*iperf* produit une erreur (voir 7.7.2 page 35).

Nous observons que la modification du délai n'entraîne pas de diminution des performances pour les liens à faibles capacités Fig. 11. Ce qui est attendu vu que la taille des *buffers* et la capacité des routeurs sont largement suffisantes pour satisfaire à une augmentation de débit. Il reste alors à tester ces cas dans des conditions plus stringentes.

Pour les liens à haute capacité, l'augmentation de délai entraîne une diminution du débit total. Pour 200 Mbit/s et 400 ms de RTT, il est nécessaire d'avoir environ 10 Mo de tampon par sous-flot. Cependant, il est possible que cette diminution drastique pour le lien à 200 Mbit/s est en partie liée aux problèmes de simulation des débits élevés avec mininet.

Nous constatons que la taille du tampon s'avère être un paramètre primordial dans les performances de MPTCP. Dans une utilisation mobile, les deux sous-flots ont généralement des délais différents (par exemple, si on se base sur l'utilisation conjointe d'un accès wifi, 3G ou/et ethernet). Dans la figure 12, nous utilisons les mêmes paramètres que dans l'expérience précédente cependant le premier sous-flot aura le même RTT (une dizaine de millisecondes) pour toutes les expériences (expériences "TC"). Nous n'observons aucune différence notable entre le cas où les deux sous-flots ont un RTT variable et dans le cas où un seul des sous-flots possède un RTT variable. L'expérience "200 TC" montre que le débit est plus élevé que l'expérience "200", cette différence peut être expliquée par une taille du tampon insuffisante.

1. <https://github.com/mininet/mininet/wiki/Introduction-to-Mininet#what-are-mininets-limitations>

2. <https://mailman.stanford.edu/pipermail/mininet-discuss/2014-January/003901.html>




FIGURE 11 – **Débit maximal mesuré en fonction du délai.** Le délai est du même ordre de grandeur pour tous les liens. Le RTT est mesuré avec la commande *ping* avant le test avec *iperf* qui dure 60 s. Deux sous-flots sont utilisés.

6.4.4 Choix du sous-flot en fonction du délai

Pour tester quels sont les sous-flots choisis par MPTCP dans une connexion à « faible » débit. Nous avons utilisé 5 sous-flots avec différents RTT. Le RTT de chaque sous-flot suit une sigmoïde (équation 2).

$$delay = min + \frac{max}{1 + e^{\frac{x - x_{half}}{slope}}} \quad (2)$$

Les paramètres¹ utilisés sont les suivants :

1. *slope* et *x_{half}* ne sont pas utiles et permettent de contraindre le nombre d'expériences et la courbure des points d'inflexion.




FIGURE 12 – **Débit total mesuré en fonction du délai d'un lien.** Le délai est modifiée seulement pour le second lien dans la topologie A (expériences "TC"). Le RTT est mesuré avec la commande *ping* avant le test avec *iperf* qui dure 60 s. Deux sous-flots sont utilisés.

Paramètre	Valeur
delay	délai par lien
max	délai maximal par lien
min	délai minimal par lien




FIGURE 13 – **Débit reçu par interface côté serveur en fonction du RTT par sous-flot.** *En haut*, RTT pour chaque sous-flot. *Au milieu*, débit (Mbit/s) par interface. *En bas*, débit total (Mbit/s) enregistré au serveur.

Nous observons que le débit reçu est globalement équivalent pour chaque interface sauf pour l'interface "eth4" où son débit est inférieur à celles des autres pour des RTTs supérieur à 300 ms. Le débit total n'est que faiblement diminué. En effet, la commande *iperf* envoie des paquets jusqu'à atteindre la capacité de chaque sous-flot. La légère diminution des débits pour les délais long est probablement liée au tampon de réception ou d'envoi.

Il est donc difficile de prédire les sous-flots utilisés par l'ordonnanceur. *iperf* ne permet

de contraindre le débit que pour des paquets UDP. Nous avons donc intégré *iperf3*¹ à la VM mininet pour permettre de fixer le débit pour des paquets TCP.

L'utilisation d'*iperf3* entraîne une erreur qui n'a pas été encore résolue à la fin de la simulation (voir 7.7.2 page 35) empêchant toutes simulations automatisées. Nous avons donc choisi deux résultats caractéristiques.




FIGURE 14 – **Débit mesuré pour chaque interface.** Les RTTs pour les interfaces de eth0 à eth5 sont de 34, 38, 43, 137, 552 ms. Chaque lien a une capacité de 10 Mbit/s et le débit total généré par *iperf3* a été fixé à 7,5 Mbit/s.

Dans la figure 14 et 15 nous observons que MPTCP envoie préférentiellement les paquets dans les sous-flots à faible RTT. Il équilibre les charges dans les sous-flots où le délai reste raisonnable (sous-flot à RTT de 147 ms dans la figure 14. Cependant pour les sous-flots à « coûts » identiques, nous observons un effet de battement (*flappiness*). Il serait utile de mesurer le RTT au cours du temps pour chaque sous-flot et d'établir si cet effet de battement est lié à une variation du délai et ce pour l'algorithme LIA et OLIA [4].

1. <https://github.com/esnet/iperf>




FIGURE 15 – **Débit mesuré pour chaque interface.** Les RTTs pour les interfaces de eth0 à eth5 sont de 43, 43, 557, 557, 557 ms. Chaque lien a une capacité de 10 Mbit/s et le débit total généré par *iperf3* a été fixé à 7,5 Mbit/s.

Une partie de ce projet consistait dans un premier temps en l'étude du code de MPTCP et de la compréhension de son fonctionnement, puis dans l'implémentation d'un nouvel ordonnanceur de notre choix. Après discussions, nous avons décidé de placer deux personnes sur l'étude du code de MPTCP car il nous semblait important d'avoir une bonne connaissance du fonctionnement du code et des principales structures pour pouvoir implémenter un nouvel algorithme d'ordonnement.

6.5 Etude de l'algorithme de MPTCP

6.5.1 Explication de l'ordonnanceur

Lors de l'étude du code de MPTCP, nous avons étudié l'ordonnanceur déjà implémenté. L'ordonnanceur de MPTCP tient dans la fonction `get_available_subflow()`, qui se trouve dans `($SRC NOYAU)/net/mptcp/mptcp.output.c`. Cela nous a été confirmé par Matthieu Coudron lorsqu'il a choisi l'ordonnanceur à implémenter. Cette fonction retourne la socket sur laquelle sera envoyée le prochain segment de données et définit la taille du Maximum Segment Size (MSS). Nous allons vous expliquer comment marche cet algorithme. Mais pour cela il faut connaître d'avance les structures principales que nous allons vous expliquer avant de commenter l'ordonnanceur.

Tout d'abord la structure `mptcp_cb` signifie *MPTCP control block* c'est la pierre angulaire de MPTCP. Elle est utilisée dans pratiquement toutes les fonctions de MPTCP. Cette structure permet de superviser les différents sous-flots utilisés pour une connexion MPTCP. Elle permet aussi de décider s'il faut ouvrir ou fermer un sous-flot, elle réordonne les données reçues afin que l'application qui a besoin de ces données les obtienne dans le bon ordre.

La structure `sock` (socket) et la structure `sk_buff` (socket buffer) sont les mêmes que dans TCP. La socket permet de créer une liaison entre les machines : elle détient les informations nécessaires à la transmission des données ; quant au socket buffer, elle permet de définir ce que doit envoyer une socket et permet de faire un tri sur les données reçues grâce aux timestamps. L'ordonnanceur implémenté dans MPTCP utilise, comme dans notre implémentation, le Smoothed Round Trip Time (SRTT) pour déterminer quelle socket enverra les données. De ce fait, si le SRTT est petit, l'ordonnanceur utilisera plus souvent cette socket. C'est ce qui crée une faiblesse dans la sécurité de la transmission alors qu'avec MPTCP, comme il y a plusieurs chemins, la complexité peut être accrue s'il y a un équilibrage dans l'envoi des données entre les sous-flots.

Nous allons maintenant nous intéresser à la fonction `get_available_subflow()` qui est l'ordonnanceur.

L'algorithme se déroule de la fonction suivante :

- Tout d'abord, il y a une vérification sur le nombre de sous-flots ouverts dans la connexion MPTCP. Il est possible de récupérer cette valeur grâce à la structure `mptcp_cb` (`mpcb->cnt_subflows`). On effectue ce test au préalable dans le cas où il n'y aurait qu'un seul sous-flot, au quel cas, il suffit de renvoyer l'unique socket s'il est disponible. Pour tester la disponibilité d'une socket, la fonction

mptcp_is_available() existe déjà. Elle vérifie qu'elle peut envoyer (vérification des champs de la socket), que la connexion est totalement établie, que la socket soit éligible et, que sa fenêtre d'envoi est suffisante. Si la fonction renvoie *true* alors le sous-flot peut être éligible pour envoyer des données. On peut récupérer les sockets via la structure *mpcb->connection_list* qui liste les sockets associées aux sous-flots.

- Sinon on regarde toutes les sockets associées à la connexion MPTCP et on distingue trois types de sockets : les backup sockets, lowpriority sockets et la meilleure socket. Dans cet algorithme, il y a des sockets qui ont une priorité basse et qui ne serviront que s'il n'existe pas de sockets avec une priorité plus grande que cette priorité. C'est ce qu'on appelle les lowpriority sockets. Parmi toutes les sockets, on choisit celle qui a le plus petit SRTT. Et on la stocke dans la variable *lowpriosk*. Bien qu'elle soit nommée lowpriority, elle a une fonction de backup mais c'est une socket éligible contrairement à la backup socket.

- Si il y a d'autres sockets qui non pas une faible priorité, on compare le SRTT de ces sockets et on garde la socket avec le RTT le plus faible. Elle est stockée dans la variable *bestsk*.

Il y a aussi une backup socket qui sert au cas ou aucune des sockets décrites ci-dessus ne peuvent envoyer un segment de données : c'est le dernier recours car celle-ci est désignée alors qu'elle ne permet pas la réinjection de données. Elle sera stockée dans la variable *backups*.

- Maintenant que nous avons défini les différents types de sockets, il faut savoir sur laquelle des trois sockets on va envoyer les données ; Si il n'y a que des sockets de backup, on envoie les données sur la *lowpriosk*. Sinon on envoie les données sur la *bestsk* si elle existe. Et s'il n'y a pas de *bestsk*, on utilise *backups*.

6.6 Choix de l'ordonnanceur

Pour le projet, il fallait choisir et implémenter un nouvel ordonnanceur. Nous avons émis plusieurs hypothèses pour ce nouvel algorithme. En accord avec les encadrants, il a été décidé de juste utiliser le SRTT des sockets pour faire notre implémentation.

Dans un premier temps, nous avons pensé implémenter un algorithme assez simpliste mais qui permettait d'augmenter la sécurité contre les attaques de type *Man In The Middle*. C'est à dire que notre algorithme allait envoyer les segments de manière équitable sur chaque sous-flots permettant l'envoi de données. Cet algorithme avait pour vocation de rendre plus difficile la récupération d'informations en écoutant un sous-flot car avec l'algorithme actuel, si un attaquant voulait récupérer un maximum d'informations, il lui suffisait d'écouter le sous-flot qui a le SRTT le plus faible. C'est ce que nous voulions éviter avec notre algorithme. Cependant après de plus amples réflexions, nous avons remarqué que notre algorithme avait un grand nombre de défauts.

En effet, MPTCP a été développé afin d'avoir une amélioration des débits mais cet algorithme aurait empêché cela si le débit d'un sous-flot était vraiment faible comparé aux

autres sous-flots alors toute la connexion MPTCP ressentirait ce débit faible et cela influerait beaucoup sur les performances de MPTCP. C'est pourquoi cet algorithme n'a pas été choisi.

Un compromis entre sécurité et performances est nécessaire pour que l'utilité de MPTCP soit avantageuse par rapport à TCP. Il nous a été proposé de sélectionner les k meilleurs sous-flots d'un point de vue du SRTT et de faire un Round-Robin sur ces k sous-flots. k étant laissé à notre appréciation. Cet algorithme est le meilleur compromis trouvé car il permet de ne pas envoyer de données sur un sous-flot si son SRTT est trop grand, ce qui permet de garder une certaine rapidité dans la transmission de données et de garder une certaine sécurité car le trafic passe de manière équitable sur les k meilleurs sous-flots.

6.7 Implémentation de l'ordonnanceur

Afin de pouvoir stocker les k meilleurs sous-flots, on avait 2 choix.

- Soit un tableau.
- Soit une liste chaînée.

Après en avoir discuté entre nous, nous avons décidé d'utiliser une liste chaînée car les listes chaînées permettent une plus grande flexibilité de manipulation. Nous avons donc déclaré dans *mptcp.h*, une structure :

```
struct selected_sk{
    struct sock *sk;
    struct selected_sk *next;
};
```

Cette structure permet de pointer sur une socket et de d'avoir un lien vers la socket suivante ce qui permet de naviguer très facilement entre les différentes sockets sélectionnées. Ce qui est très utile pour le Round-Robin.

Une fois que l'on avait déclaré cette structure, il fallait aussi implémenter des fonctions afin de pouvoir faire une liste chaînée en fonction des RTT. Notre liste chaînée sera organisée de telle sorte :

On aura une *selected_sk* qui sera appelée *bssk*. C'est la "best selected socket". Ça sera la socket sélectionnée qui aura le meilleur RTT, puis son attribut *next* pointera sur la deuxième sockets avec le meilleur RTT. Et la k^{eme} socket aura pour *next* la *bssk*. Cela formera une boucle. Les fonctions que l'on a créés sont :

- *static void ssk_insertion_sort(struct selected_sk *bssk, int ssk_size);* : qui permet de faire en sorte que la liste chaînée soit triée en fonction du Smoothed RTT (SRTT) des sockets.
- *static u32 ssk_max_srtt(struct selected_sk *bssk);* : permet de retourner la valeur maximale du SRTT de la liste chaînée, c'est à dire le RTT de la socket qui a pour *next* la *bssk* passée en argument.

- *static int belongto_ssk(struct sock *sk, struct selected_sk *bssk, int ssk_size);* : permet de savoir si la socket sk passée en argument appartient à la liste chaînée.
- *static struct selected_sk *bssk_prev(struct selected_sk *bssk);* : permet d'obtenir la socket ayant le plus grand SRTT de la liste chaînée. C'est la socket précédant la bssk.
- *static void ssk_checkup(struct sk_buff *skb, struct selected_sk *bssk, int ssk_size);* : permet de retirer les sockets de la liste chaînée si elles ne sont pas capable d'envoyer des données (!mptcp_is_available(it->sk, skb, &this_mss)) et si on a déjà mis dans la queue de la socket le buffer skb (mptcp_dont_reinject_skb(tp, skb)).

Où *ssk_size* est le nombre de socket qui forme la liste chaînée.

Avec ces fonctions nous pouvons créer la fonction principal que l'on placera dans *static struct sock *get_available_subflow(struct sock *meta_sk, struct sk_buff *skb, unsigned int *mss_now);*

Nous allons maintenant expliquer comment fonctionne la fonction principale : On vérifie tout d'abord si tous les sockets de la liste chaînée ont envoyé une fois (si elles existent toujours) et si oui, on recalcule la liste chaînée. Dans cette boucle qui permet d'établir cette liste chaînée, on teste chaque socket si elle est disponible. Si la socket a un meilleur SRTT ou qu'il reste de la place dans les k meilleures sockets, on rajoute cette socket dans la liste. Pour cela, une insertion est effectuée en gardant la liste triée. Par contre, si le SRTT est plus grand que ceux de la liste chaînée et qu'il y a déjà k sockets, on passe à la socket suivante.

7 Annexe1

7.1 Utilisation des scripts pythons

7.1.1 Activation MPTCP

Il y a deux fichiers qui nous intéressent :

```
/proc/sys/net/mptcp_path_manager  
/proc/sys/net/mptcp_enabled
```

Le fichier `enabled` permet d'activer (1) ou de désactiver (0) MPTCP sur la machine.

Le fichier `path_manager` influence sur la méthode d'annonce des sous-flots. Deux valeurs nous intéressent : *fullmesh*, et *default*. La valeur *default*, il n'y a pas d'annonces des sous-flots disponibles tandis que *fullmesh* permet la création d'un *mesh* de sous-flots parmi tous ceux disponibles.

Pour modifier la valeur du fichier, il suffit d'utiliser `sysctl` en utilisant la forme "nom=valeur"

```
sudo sysctl -w net.mptcp.mptcp_path_manager=fullmesh  
sudo sysctl -w net.mptcp.mptcp_enabled=1
```

Attention, selon les choix lors de la compilation du noyau, la valeur par défaut du `path_manager` peut être mise sur "default".

7.1.2 Choix de l'algorithme congestion

Pour choisir l'algorithme de congestion, il est nécessaire de modifier le fichier suivant :

```
/proc/sys/net/ipv4/tcp_congestion_control
```

Pour l'algorithme LIA :

```
sudo sysctl -w net.ipv4.tcp_congestion_control=coupled
```

Pour l'algorithme OLIA :

```
sudo sysctl -w net.ipv4.tcp_congestion_control=olia
```

Pour l'algorithme par défaut :

```
sudo sysctl -w net.ipv4.tcp_congestion_control=cubic
```

Pour afficher les algorithmes disponibles :

```
sudo sysctl net.ipv4.tcp_available_congestion_control
```

L'ordonnanceur par défaut est choisi à la compilation du noyau.

7.1.3 Taille de la fenêtre

Pour modifier la taille maximale de la fenêtre de réception (*rmem*) et d'envoi *wmem*, il faut modifier les fichiers suivants :

```
/proc/sys/net/core/wmem_max
/proc/sys/net/core/rmem_max
/proc/sys/net/core/rmem_default
/proc/sys/net/core/rmem_default
```

Pour une taille *buffer* maximale de ~ 16 Mo :

```
sysctl -w net.core.wmem_max=16777216
sysctl -w net.core.rmem_max=16777216
```

Pour modifier les valeurs par défauts :

```
sysctl -w net.core.rmem_default=163840
sysctl -w net.core.wmem_default=163840
```

Pour modifier les valeurs d'*auto-tuning* :

```
sysctl -w net.ipv4.tcp_wmem='4096 16384 4194304'
sysctl -w net.ipv4.tcp_rmem='4096 87380 6291456'
```

Les valeurs correspondent respectivement à la taille minimale, par défaut et maximale du buffer alloué (en octets) par socket TCP. La taille maximale ne peut dépasser celle indiquée dans *net.core*.

7.2 Lancement scripts python

Les fichiers permettant de lancer la topologie et d'exécuter les tests se nomment en commençant par "pyMPTCP" et se situent sur le git pour l'instant dans `./mininet/python/TCPvsMPTC`.

```
pyMPTCP.py
pyMPTCP_parser.py
pyMPTCP_topo.py
pyMPTCP_options.py
```

`pyMPTCP.py` contient le *main* et doit être modifié pour choisir la topologie (objet *topo* dans la fonction *main* et objet *net* dans la fonction *runMPTCP*).

`pyMPTCP_topo.py` contient les définitions des topologies utilisées. La classe *Topo* sera utilisée par mininet pour la création du réseau. La classe *Topo->names* contient les noms des hôtes et des switches qui seront utiles pour les tests.

`pyMPTCP_parser.py` contient le parseur d'argument voir section 7.4.

`pyMPTCP_options.py` contient les fonctions qui seront lancées selon les arguments utilisés.

La fonction `options` permet de modifier la topologie après la création des nœuds. À cause d'un bug de `mininet`, pour l'instant encore non résolu, il est nécessaire d'utiliser la classe `mininet` pour pouvoir créer plus d'un lien entre deux mêmes nœuds.

Exemple d'utilisation :

```
sudo python ./pyMPTCP.py -0 exp001_TC --bw 10 --mptcp -n 5 -t 60 --shark
```

Ici nous lançons la topologie A, avec l'expérience `exp001_TC` avec un débit maximal par lien de 10 Mbit/s, en utilisant MPTCP, avec 5 sous-flots et `iperf` sera utilisé pendant 60 secondes, et `tcpdump` sera utilisé pour enregistrer les paquets. Pour plus de précisions voir 7.4.

7.3 Résumé des arguments pour le parseur

Les commentaires des arguments sont disponibles dans la section 7.4.

```
usage: sudo mptc_khal.py [h] [--cli] --bw BW [--delay DELAY] [-n N] [-t T]
        [--mptcp] [--pause] [--ndiffports NDIFFPORTS]
```

Description

<code>--cli</code>	lance le mode <i>command line interface</i> avant le lancement de l'expérience
<code>--csv</code>	la sortie de la commande <code>iperf</code> est formatée en csv
<code>--delay, -D n</code>	fixe le délai de tous les liens
<code>--dump</code>	lance <code>tcpdump</code> sur toutes les interfaces utilisant mptcp et écrit la sortie dans un fichier de type [hôte]-[if].pcap
<code>--file, -F <filename></code>	fichiers de sortie, un pour le client et un pour le serveur. Par défaut, aucun fichier n'est créé.
<code>--pause</code>	pause après la simulation
<code>--sshd</code>	lance <code>sshd</code> sur chaque hôte. Connexion du réseau à l'espace de nom de la racine.
<code>--t n</code>	<i>iperf</i> durée en seconde de l'expérience
<code>--tc</code>	active la modification des liens via <i>tc</i>

exemple :

```
sudo mptc_khal.py --cli --delay "50ms"
```

7.4 arguments mininet

```
usage: sudo mptc_khal.py [h] [--cli] --bw BW [--delay DELAY] [-n N] [-t T]
        [--mptcp] [--pause] [--ndiffports NDIFFPORTS]
```

cf argument parser annexe.

7.4.1 ssh

usage: `sudo mptc_khal.py --sshd`

Cette option lance le démon ssh dans chacun des nœuds avec la commande

```
/usr/sbin/sshd -o UseDNS=no -u0
```

Pour l'instant, seul la connexion à partir de root avec le premier hôte (172.16.0.1) fonctionne. En effet la résolution ARP échoue pour les autres hôtes (pas de paquets ARP reply en utilisant tcpdump).

sur le nœud root

```
tcpdump -i root-eth0 arp
```

Cependant, il reste possible de se connecter aux autres hôtes par ssh via le premier hôte.

Pour l'instant, une méthode « sale » est utilisée pour arrêter les démons sshd sur les hôtes.

7.5 scripts shell

Les scripts écrits en bash permettent de lancer plusieurs fois les simulation en utilisant des paramètres variables. Il est nécessaire de les lancer en mode super-utilisateur.

```
sudo bash shNAME.sh
```

shKernelCheck.sh Permet de visualiser l'algorithme de congestion et les taille des tampons

shKernelDefault.sh Permet de modifier les tailles des buffers

shMPTCP.sh lanceurs d'expériences

Le script shMPTCP permet de multiplier les expériences. Les fonctions écrites ne sont pas toutes utilisées cependant il y a 2 fonctions importantes qu'on peut décrire.

clean

```
sudo bash shMPTCP.sh clean
```

Cette fonction envoie un signal d'arrêt aux fonctions qui sont utilisées pour les mesures : (ping, iperf, iperf3, bwm-ng, tcpdump), elle supprime tous les fichiers de sortie situés dans ./output/ et effectuer un nettoyage de "mininet" (mn -c) en supprimant les noeuds, liens hôtes créés.

runMPTCP Cette fonction exécute le script python est appelé à l'intérieur d'une boucle par d'autres fonctions.

Les autres fonctions appellent la fonction runMPTCP pour effectuer les simulations, exemple :

```
sudo bash shMPTCP.sh runbw
```

7.6 Scripts R

Les scripts R ne sont pas totalement finalisés pour être exploitables facilement par autrui et pour certains, il faudra modifier les fichiers pour indiquer les dossiers contenant les résultats des expériences.

Le dossier ./scripts/R contient les fonctions qui permettent d'analyser les fichiers produits par les scripts pythons.

Le dossier ./scripts/Analysis contient les fichiers expérimentaux et les fichiers R permettant de les analyser en faisant appel aux fonctions se trouvant dans le dossier ./scripts/R. Pour une question de stockage, les fichiers des différentes expériences ne sont pas sur le git.

7.7 Bugs

7.7.1 Topologie

À la création de la topologie mininet, il est nécessaire de donner des noms courts aux hôtes et aux switches.

Il n'est pas possible de créer deux liens entre les mêmes nœuds de la classe "Topo". Pour contourner cette limitation, il faut créer la topologie avec un seul lien puis dans la classe "Mininet", rajouter le second lien. C'est pourquoi, dans le fichier "*pyMPTCP_topo.py*", il y a deux définitions pour la même topologie : une pour la classe Topo (*topo()*) et une autre pour la classe Mininet (*topo_options(args,net)*) qui sera exécuté séquentiellement lors de la simulation.

7.7.2 mininet

iperf et ping L'utilisation conjointe de la commande *iperf* et de la commande ping dans une simulation produit une erreur du calcul du délai par la commande ping. Ce délai augmente exponentiellement vers environ 1000 ms. Si on analyse les traces enregistrés avec *tcpdump*, les réponses aux *echo request* se produisent bien plus rapidement que ne laissent suggérer les résultats de la commande *ping*. L'utilisation conjointe de ces deux applications marchent très bien entre la machine physique et la VM et il est probable que ce problème

soit lié à mininet.

MSS Lorsque nous fixons le *Maximum Segment Size* à 1460 octets, nous obtenons ce message d'erreur :

```
WARNING: attempt to set TCP maximum segment size to 1460, but got
536
```

Cependant, si nous analysons les paquets enregistrés grâce à *tcpdump*, nous observons que le MSS négocié pendant le *handshake* de la connexion est bien de 1460 octets et que la taille des paquets de données est de 1428 octets.

iperf3 Dans l'état des scripts, *Iperf3* produit une erreur à la fin de la simulation. Il est nécessaire de nettoyer la simulation et il n'est pas possible pour l'instant d'utiliser les scripts *shell* pour effectuer des simulations automatisées.

```
sudo bash shMPTCP.sh clean
```

7.8 Expériences

Description des fichiers pythons dans le dossier experiment

```
TCPvsMPTCP/
  __init__.py
  pyMPTCP.py
  experiment/
    __init__.py
    experiment.py
    experiment001_TC.py
    ...
```

fichier	Commentaires
experiment.py	fixe délai h1-eth1, valeur à modifier dans le fichier
exp001_TC.py	fixe délai h1-eth1, valeur à modifier dans le fichier
exp002_TCping	même caractéristiques que exp001, le ping est mesuré pendant la mesure de débit.
exp003_TCpingws	cf exp002. arg1 est utilisé pour modifier la fenêtre TCP dans iperf « -w n »

Références

- [1] A. Ford, C. Raiciu, M. Handley, S. Barre, and J. Iyengar, “Architectural guidelines for multipath tcp development,” *RFC 6182*, March 2011. (Cité en pages 3, 8 et 18.)
- [2] A. Ford, C. Raiciu, M. Handley, and O. Bonaventure, “Tcp extensions for multipath operation with multiple addresses,” *RFC 6824*, January 2013. (Cité en pages 3 et 19.)
- [3] M. Coudron, S. Secci, G. Pujolle, P. Raad, and P. Gallard, “Cross-layer cooperation to boost multipath tcp performance in cloud networks,” in *Cloud Networking (CloudNet), 2013 IEEE 2nd International Conference on*, pp. 58–66, IEEE, 2013. (Cité en pages 3 et 10.)
- [4] R. Khalili, N. Gast, M. Popovic, U. Upadhyay, and J.-Y. Le Boudec, “Mptcp is not pareto-optimal : Performance issues and a possible solution,” *Networking, IEEE/ACM Transactions on*, vol. 21, no. 5, pp. 1651–1665, 2013. (Cité en pages 3, 10, 13, 16 et 25.)
- [5] R. Stewart, “Stream control transmission protocol,” *RFC 4960*, September 2007. (Cité en page 8.)
- [6] D. Thaler, Microsoft, C. Hopps, and N. Technologies, “Multipath issues in unicast and multicast next-hop selection,” *RFC 2991*, November 2000. (Cité en page 8.)
- [7] C. Raiciu, M. Handley, and D. Wischik, “Coupled congestion control for multipath transport protocols,” *RFC 6356*, October 2011. (Cité en pages 9 et 16.)
- [8] C. Raiciu, C. Pluntke, S. Barre, A. Greenhalgh, D. Wischik, and M. Handley, “Data center networking with multipath tcp,” in *Proceedings of the 9th ACM SIGCOMM*, pp. 58–66, IEEE, 2010. (Cité en page 10.)